Clase Nº 8

Archivos

Introducción

- Hasta ahora todo el manejo de datos se realizó con variables o con listas.
- Ambas tienen en común que se almacenan en la memoria principal del computador.
- Esta memoria requiere alimentación eléctrica permanente para conservar su contenido.

Introducción

- Para que los datos perduren en el tiempo es necesario almacenarlos en dispositivos externos que no requieran energía para su conservación.
- A través del tiempo se han usado distintas tecnologías con este propósito.

Introducción

Tarjetas perforadas

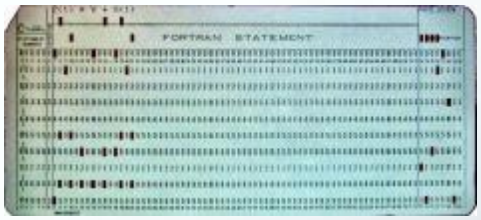

Cintas magnéticas

Introducción

Discos

Memorias no volátiles

Concepto

- Cualquiera sea el dispositivo en el que se almacenen los datos, lo que se estará guardando será siempre un ***archivo***.
- Un *archivo* es un conjunto de elementos llamados **registros**, todos del mismo tipo de dato, que se almacena en un dispositivo auxiliar para preservar la información a través del tiempo.

Concepto

- Habitualmente cada registro contiene varios datos referidos a un mismo sujeto.
- Si el sujeto es una persona, estos datos suelen incluir su nombre, número de documento, fecha de nacimiento, domicilio, etc.

Concepto

- Si el sujeto es un producto, los datos contendrán el código interno de inventario, su descripción, precio de costo, cantidad en stock, etc.
- A cada uno de estos datos se lo denomina **campo**.

Concepto

Resumiendo:

- **Un archivo es un conjunto de registros.**
- **Un registro es un conjunto de campos.**

Concepto

Clasificación de archivos

Según el sentido de la transferencia de datos:

- **Archivos de entrada: En ellos sólo se puede leer, pero no es posible grabar datos.**
- **Archivos de salida: En ellos sólo se puede grabar; no es posible leer.**

Archivos en Python

- **En Python se utilizan archivos de texto, es decir archivos formados por cadenas de caracteres.**
- **Estas cadenas contienen sólo texto. No hay distintas tipografías, subrayados, negritas, etc. Es lo que se denomina *texto plano*.**

Archivos en Python

- Los archivos de texto pueden ser creados, visualizados o modificados a través de cualquier editor de texto, como el Block de Notas de Windows o el IDLE de Python.
- Generalmente tienen extensión ".txt".

Ejemplo de un archivo

Súbeme la radio que ésta es mi canción
Siente el bajo que va subiendo
Tráeme el alcohol que quita el dolor
Hoy vamos a juntar la luna y el sol

Ya no me importa nada
Ni el día ni la hora
Si lo he perdido todo
Me has dejado en las sombras

Registros

- Cada línea de un archivo de texto constituye un ***registro***.
- En los archivos de texto la longitud de las líneas es variable, y por lo tanto lo es también la longitud de registro.
- Ésto obliga a colocar un separador entre cada registro. A este separador se lo conoce como **delimitador**.

Delimitadores

- El delimitador que se utiliza es la secuencia de escape "\n", que representa al salto de línea:

L	u	n	e	s	\n	M	a	r	t	e	s	\n	M	i	é	r	c	o	l	e	s	\n

Lunes
Martes
Miércoles

Delimitadores

- El programa grabará "\n" como delimitador entre cada registro, pero el carácter efectivamente grabado dependerá del sistema operativo que se esté usando.
- A este proceso de traducción del delimitador se lo conoce como **conversión de datos**, y es exclusivo de los archivos de texto.

Delimitadores

\n

Windows: Retorno de carro (CR)
Avance de línea (LF)

Linux/Android: Avance de línea

macOS: Retorno de carro

Las tres etapas en el trabajo con archivos

- Apertura
- Procesamiento
- Cierre

Apertura

- Todo archivo debe ser ***abierto*** antes de ser utilizado.
- Durante la apertura se establecen canales de comunicación con el dispositivo donde reside el archivo y se reserva memoria para los ***buffers***.

Apertura

- La apertura se realiza con la función open( ):

  <var> = open(<nombre>[,<modo>])

- <var> es la variable que se usará para representar al archivo dentro del programa. Todo el trabajo con el archivo se hará a través de ella.

  arch = open("datos.txt", "rt")

Apertura

- El nombre puede incluir la ruta deseada.

  arch = open("c:\nuevo\datos.txt", "wt")

- Si no se incluye ruta al archivo se busca en la misma carpeta donde se encuentra el programa.

Apertura

- **ATENCIÓN: Esta ruta es inválida, por el salto de línea ("\n") incluido en ella.**

```
arch = open("c:\nuevo\datos.txt", "wt")
```

- **Para evitar este error existen tres posibilidades.**

Apertura

1. **Usar *doble barra invertida*:**

```
arch = open("c:\\nuevo\\datos.txt", "wt")
```

- **La doble contrabarra es también una secuencia de escape que representa a una sola barra invertida.**

Apertura

2. Usar ***una sola*** barra *normal*:

```
arch = open("c:/nuevo/datos.txt", "wt")
```

3. Declarar la cadena como *cruda*:

```
arch = open(r"c:\nuevo\datos.txt", "wt")
```


Apertura

- El modo de apertura está formado por uno o dos caracteres.
- El primero es el modo básico de apertura y puede ser r (*read*), w (*write*) o a (*append*).

Apertura

- **r (*read*): Abre el archivo en modo entrada, es decir para *lectura solamente*.**
- **El archivo tiene que existir. En caso contrario se producirá un error.**

Apertura

- **w (*write*): Abre el archivo en modo salida, es decir para *grabación solamente*.**
- **Si el archivo no existe, será creado.**
- **Si el archivo ya existe, será destruido.**

Apertura

- **a (*append*): Abre el archivo en modo salida, es decir para grabación solamente y *agregado de registros*.**
- **Si el archivo no existe, será creado.**
- **Si el archivo ya existe, todas las grabaciones se realizarán al final de los datos actuales.**

Apertura

- **El segundo carácter del modo de apertura es el modificador t (*texto*).**
- **Si se omite el modo de apertura se asume "rt" (lectura, texto).**

Apertura

- Si la apertura fue exitosa, open( ) devuelve un ***objeto archivo*** que será asignado a una variable.
- Si ocurre algún problema, se produce una excepción.
- Por este motivo todo archivo deberá abrirse siempre dentro de un ***bloque protegido***.

Apertura

- Los errores que pueden producirse durante la apertura son diversos:
  - Nombre inválido
  - Archivo de lectura inexistente
  - Disco lleno
  - Disco protegido contra escritura
  - Permisos insuficientes
  - Archivo en uso

Cierre

- Durante el cierre se revierte todo lo que se hizo en la apertura.
- Se clausuran los canales de comunicación con el dispositivo y se liberan los buffers, grabando cualquier registro pendiente que pudiera haber.

Cierre

- Para cerrar un archivo se utiliza el método *close()* de la variable que representa al archivo:

```
arch.close()
```

- Debido a la importancia del cierre, se suele realizar en la cláusula finally.

Cierre

- En muchas implementaciones de Python, intentar cerrar un archivo que no consiguió abrirse provocará un error.
- Se soluciona con un bloque protegido dentro del finally:

```
finally:
    try:
        arch.close( )
    except NameError:
        pass
```


Procesamiento

- El procesamiento de un archivo consiste en realizar lecturas y grabaciones sobre el mismo.
- Existen dos maneras distintas para grabar y tres para leer.
- Todas se realizan con métodos.

Métodos de grabación

- **<arch>.write(<str>): Graba <str> en el archivo. El salto de línea debe añadirse manualmente, porque este método no lo agrega.**
- **<arch>.writelines(<lista>): Graba una lista de cadenas. El salto de línea debe añadirse manualmente a cada elemento de la lista.**

Ejemplo 1

Leer desde el teclado los datos correspondientes a los alumnos de un curso (legajo y nombre) y grabarlos en un archivo CSV (*comma-separated values*, valores separados por comas)*.

El fin de datos se indica ingresando un legajo vacío (Enter).

** CSV es uno de los formatos posibles en archivos de texto. No todos los archivos de texto son CSV.*

```
try:
    arch = open("alumnos.txt","wt")
    lu = input("LU? (Enter para terminar): ")
    while lu!="":
        nombre=input("Nombre? ")
        arch.write(lu+';'+nombre+'\n')
        lu = input("LU? (Enter para terminar): ")
    print("Archivo creado correctamente.")
except OSError as mensaje:
    print("No se puede grabar el archivo:", mensaje)
finally:
    try:
        arch.close()
    except NameError:
        pass
```


Ejemplo del archivo

```
1042735;Vignale, Juan José
1118693;Garay, Mariela Daiana
1094219;Zanini, Candela Belén
1008752;Blanco, Rodrigo Axel
```

(Obsérvese que al final del registro no se agrega punto y coma)

Excepciones y archivos

- La clase *OSError* usada en el ejemplo anterior es una clase de excepción muy general.
- Agrupa problemas tan diversos como disco lleno, ruta de acceso inválida, permisos insuficientes o archivo inexistente.

Excepciones y archivos

- Por esta razón se prefiere usar OSError como medida de último recurso, creando antes otros manejadores de excepciones más específicos.
- Se recomienda capturar la excepción *FileNotFoundError* antes de OSError, tanto en archivos de entrada como de salida.

Métodos de lectura

- **<arch>.read([<n>]): Lee un archivo de texto y devuelve una única cadena de caracteres. Este método lee el archivo entero, lo que puede ser *muy peligroso* con archivos grandes. Si se incluye el parámetro opcional <n> se lee esa cantidad de caracteres.**
- **Una posibilidad aceptada es escribir un 1 como parámetro, para leer un carácter por vez.**

Métodos de lectura

- **<arch>.readline( ): Lee una sola línea del archivo y la devuelve como valor de retorno, o una cadena vacía si no hay más datos.**
- **Éste será el método de lectura preferido, ya que permite leer un registro por vez.**

Atención

- En este curso no se permitirá ***bajo ningún concepto*** la carga de archivos completos en memoria*, ya que constituye una pésima práctica de programación, comparable a un ciclo infinito.
- Otros lo hacen. Nosotros no.

(*) Se considera *memoria* a un string, una lista o cualquier otro tipo de estructura de datos.

Métodos de lectura

- **<arch>.readlines( ): Lee el archivo entero y lo devuelve como una lista de cadenas.**
- **El uso de este método no será admitido en este curso.**

Prohibido

Ejemplo 2

Leer el archivo generado en el ejemplo anterior e imprimir por pantalla los datos de aquellos alumnos cuyo número de legajo sea menor a 1.000.000.


```
try:
    arch = open("alumnos.txt","rt")
    linea = arch.readline( )
    while linea:
        lu, nombre = linea.split(';')
        nombre = nombre.rstrip('\n')
        if int(lu)<1000000:
            print(f"LU: {lu:>7} - Nombre: {nombre}")
        linea = arch.readline( )
    print("Archivo leido correctamente.")
except FileNotFoundError as mensaje:
    print("No se puede abrir el archivo:", mensaje)
except OSError as mensaje:
    print("No se puede leer el archivo:", mensaje)
finally:
    try:
        arch.close( )
    except NameError:
        pass
```

Indicador de posición

- El **indicador de posición** -también llamado indicador de registro activo o puntero de lectura/escritura- es un señalador que le indica al sistema cuál es el próximo registro que se va a leer o grabar.

Indicador de posición

- Este indicador avanza automáticamente con cada operación de lectura o escritura.
- De esta manera el sistema conoce cuál es el próximo registro a leer o grabar.

Indicador de posición

- **Al terminar la lectura del archivo el indicador de posición queda señalando al final del mismo.**
- **Por eso resulta imposible volver a leerlo *a menos que se haga algo*.**

Indicador de posición

Alternativa 1:

- **Cerrar el archivo y volverlo a abrir. No se recomienda debido al alto costo en materia de recursos. ▼**
- **Por esta razón se admite cerrar y volver a abrir el archivo sólo cuando el modo de apertura sea diferente del anterior.**

Indicador de posición

Alternativa 2:

- **Utilizar el método seek(0) del objeto archivo:**

```
arch.seek(0)
```

- **Esto regresa el indicador de posición al comienzo de los datos.**

Ejemplo 3

Mismo ejemplo anterior, pero resuelto con la instrucción for aplicada a un archivo. Esto es posible porque un archivo es considerado un *iterable*, lo que evita tener que utilizar métodos de lectura.

```
try:
    arch = open("alumnos.txt","rt")
    for linea in arch:
        lu, nombre = linea.split(';')
        nombre = nombre.rstrip('\n')
        if int(lu)<1000000:
            print(f"LU: {lu:>7} - Nombre: {nombre}")
    print("Archivo leido correctamente.")
except FileNotFoundError as mensaje:
    print("No se puede abrir el archivo:", mensaje)
except OSError as mensaje:
    print("No se puede leer el archivo:", mensaje)
finally:
    try:
        arch.close( )
    except NameError:
        pass
```


Importante

- **Recorrer un archivo con un ciclo for *no puede ser combinado* con los métodos de lectura read o readline.**
- **Intentar hacerlo provocará pérdida de datos.**

Importante

```
arch = open("alumnos.txt","rt")
for linea in arch:
    lu, nombre = linea.split(';')
    nombre = nombre.rstrip('\n')
    if int(lu)<1000000:
        print(f"LU: {lu:>7} - Nombre: {nombre}")
    linea = arch.readline( )
```

Mal

Ejemplo 4

Leer un archivo de texto y mostrar la palabra más larga que contenga.
Si hay más de una se mostrará cualquiera de ellas.

```
try:
    arch = open("notas.txt","rt")
    maslarga = ""
    for linea in arch:
        linea = linea.rstrip("\n")
        listadepalabras = linea.split( )
        for palabra in listadepalabras:
            if len(palabra)>len(maslarga):
                maslarga = palabra
    print("La palabra más larga es:", maslarga)
except FileNotFoundError as mensaje:
    print("No se puede abrir el archivo:", mensaje)
except OSError as mensaje:
    print("No se puede leer el archivo:", mensaje)
finally:
    try:
        arch.close( )
    except NameError:
        pass
```


Ejemplo 5

Convertir a mayúsculas el contenido del archivo "notas.txt".

Como los archivos de texto no se pueden alterar, crearemos una versión modificada llamada "notas2.txt"

```
try:
    entrada = open("notas.txt","rt")
    salida = open("notas2.txt","wt")
    k = 0
    for linea in entrada:
        salida.write(linea.upper( ))
        k = k + 1
except FileNotFoundError as mensaje:
    print("No se puede abrir el archivo:", mensaje)
except OSError as mensaje:
    print("ERROR: ", mensaje)
else:
    print("Copia finalizada. Líneas copiadas:", k)
finally:
    try:
        entrada.close( )
        salida.close( )
    except NameError:
        pass
```


Recomendaciones

- No se le debe preguntar al usuario el nombre de los archivos.
- Éstas son decisiones que debe tomar el programador.

Recomendaciones

- Los archivos se abren, se procesan y se cierran.
- No debe abrirse y cerrarse el archivo por cada registro leído o grabado, ya que los tiempos de procesamiento se dispararían. ▼

Recomendaciones

- No debe leerse ni grabarse por campos; toda lectura o grabación debe afectar al registro completo. ▼
- Esto se debe a razones de eficiencia.

Recomendaciones

- Es necesario minimizar* la cantidad de veces que se recorren los archivos. ▼
- Recuerde que pueden contener *millones* de registros.

(*) Reducir al mínimo posible

Recomendaciones

- Si se produce una excepción de tipo ***UnicodeDecodeError*** o si los caracteres regionales aparecen dañados, el archivo fue creado con codificación UTF-8.
- En estos casos es necesario agregar un parámetro más en la apertura del mismo:

```
arch = open("datos.txt", "rt", encoding="UTF8")
```

Recomendaciones

- **Los archivos de texto generados con codificación UTF8 contienen bytes adicionales al inicio, lo que se conoce como *cabecera*.**
- **Por ese motivo el parámetro encoding="UTF8" sólo se agregará a la función open( ) cuando sea estrictamente necesario.**

Ejercitación

- **Práctica 6: Completa**

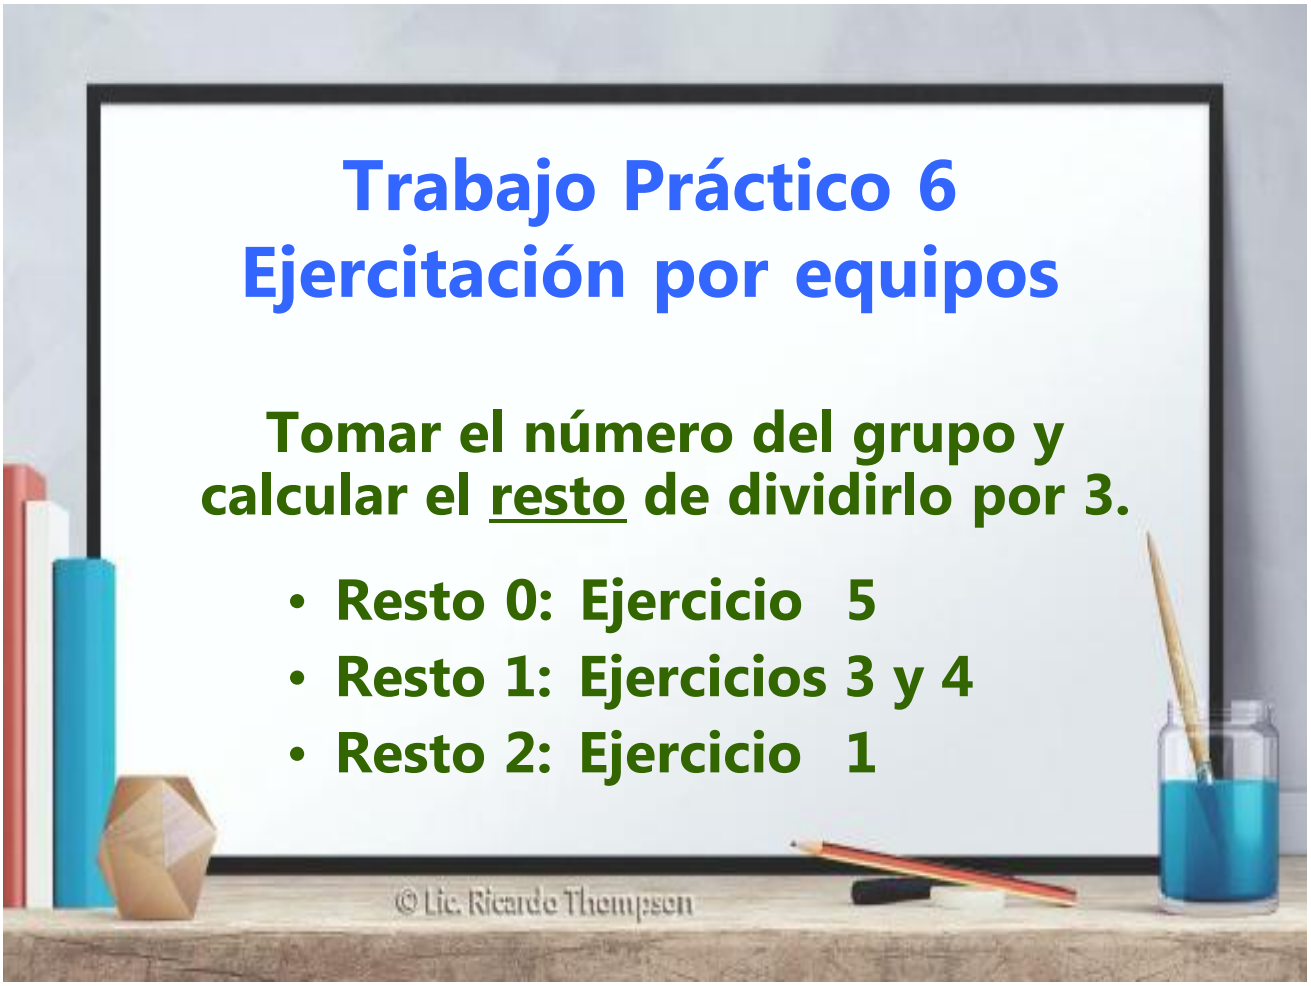
Trabajo Práctico 6
Ejercitación por equipos
Tomar el número del grupo y calcular el resto de dividirlo por 3.
• Resto 0: Ejercicio 5
• Resto 1: Ejercicios 3 y 4
• Resto 2: Ejercicio 1
© Lic. Ricardo Thompson